

## Означения

$S$  - сторона внешней окружности в клетках  
 $B$  - размер  $S$  ширины  $(H = W = S)$

$C_{in}, C_{out}$  - число вершин и внешних ребер  
 $k$  - размер края вершин  
 $S$  - шаг вершин

$H_{out}, W_{out}$  - высота и ширина внешней окружности  
 $S^2$  - число клеток внешней окружности

Размер внешней окружности

$$H_{out} = \frac{H + 2p - k}{S} + 1$$

$p = k//2$  - размер  $S$ ,  $qk$  нечетное  $\Rightarrow 2p - k = -1 \Rightarrow$

$$\Rightarrow H_{out} = \frac{H - 1}{S} + 1$$

при  $S=1$  это  $H$ , при  $S=2$  и четном  $H$  это  $H/2$

Итого: ширина  $S=1$  сохраняет размер,  $S=2$  делит его пополам.  $Max P_{out}$   $3 \times 3$ ,  $S=2$ ,  $p=1$  тоже делит пополам

| <u>Семь</u><br>сери           | $C_{in} \rightarrow C_{out}, k, s$ | формула                      | $S^2$ | нагрузка    |
|-------------------------------|------------------------------------|------------------------------|-------|-------------|
| brn                           | —                                  | $3, 5, 5$                    | 3     | —           |
| conv 1                        | $3 \rightarrow 32, 7, 2$           | $32 \cdot (\frac{5}{2})^2$   | 8     | 4704        |
| max pool                      | $3 \times 3, 5, 2$                 | $32 \cdot (\frac{5}{4})^2$   | 2     | —           |
| conv 2                        | $32 \rightarrow 64, 5, 1$          | $64 \cdot (\frac{5}{4})^2$   | 4     | 51200       |
| conv 3                        | $64 \rightarrow 128, 3, 2$         | $128 \cdot (\frac{5}{8})^2$  | 2     | 73728       |
| conv 4                        | $128 \rightarrow 256, 1, 1$        | $256 \cdot (\frac{5}{8})^2$  | 4     | 32768       |
| conv 5                        | $256 \rightarrow 256, 3, 2$        | $256 \cdot (\frac{5}{16})^2$ | 1     | 585824      |
| conv 6                        | $256 \rightarrow 512, 1, 1$        | $512 \cdot (\frac{5}{16})^2$ | 2     | 131072      |
| GAP, fc $512 \rightarrow 156$ | —                                  | $512, 256, 100$              | —     | $-131328 +$ |
| fc $256 \rightarrow 100$      | —                                  | —                            | —     | 25700       |

## FLOPS

Одна формула расчета операций  $\rightarrow C_{in} \cdot k^2$   
 умножение со сложением (MAC), а формула расчета  
 $B \cdot C_{out} \cdot H_{out} \cdot W_{out} \Rightarrow MAC = B \cdot C_{out} \cdot H_{out} \cdot W_{out}$   
 $\cdot C_{in} \cdot k^2$   
 $1 MAC = 2 FLOP$

- conv 1 :  $(\frac{5}{2})^2 \cdot 32 \cdot 3 \cdot 48 = 1176 S^2$
- conv 2 :  $(\frac{5}{4})^2 \cdot 64 \cdot 32 \cdot 25 = 3200 S^2$
- conv 3 :  $(\frac{5}{8})^2 \cdot 128 \cdot 64 \cdot 8 = 1152 S^2$

$$\text{conv 4: } \left(\frac{5}{8}\right)^2 \cdot 256 \cdot 128 = 512 s^2$$

$$\text{conv 5: } \left(\frac{5}{16}\right)^2 \cdot 256 \cdot 256 \cdot 8 = 2304 s^2$$

$$\text{conv 6: } \left(\frac{5}{16}\right)^2 \cdot 512 \cdot 256 = 512 s^2$$

$$\text{сумма } 8856 s^2$$

$$\text{FLOPs} = 2 \cdot (8856 s^2 + 156672 B) = 17712 B \cdot s^2 + 313344 B$$

## Память

В памяти GPU не хватает всего:

- вес  $W \rightarrow 416/296$  байт

- bias  $\times (3 \cdot s^2 \text{ весов на карту})$

MaxPool на CUDA функционально работает  
как один нейронный слой, в нем не хранят  
числа bias в int64

max  $\text{число весов в памяти (кратно } w)$

conv 1  $x(3) + \text{bias conv1}(8)$

maxpool  $x(3) + \text{bias conv1}(8) + \text{bias pool}$   
+  $\text{сложения (2 по 8 байт)} (2)$

байт на  
карту

$$(7+8) \cdot 4 = 44 s^2$$

$$(3+8+2) \cdot 4 + 7 \cdot 8 = 68 s^2$$

conv 2  $x(3) + \text{bias pool} + \text{bias conv2}(4)$

$$9 \cdot 4 = 36 s^2$$

final  $\text{уменьшение нейронов}$

$$\leq 36 s^2$$

$$\text{Memory} = 4161296 + 68B \cdot S^2$$

## Традиции

Q - сколько байт введено реф DRAM.

Байт на  $B \cdot S^2$

- conv1:  $(3+8) \cdot 4 = 44$

- relu1: 64

- pool:  $32 + 8 + 16 = 56$

- conv2-6:  $24 + 24 + 24 + 20 + 12 = 104$

- relu2-6:  $32 + 16 + 32 + 8 + 16 = 104$

Сумма: 380

Генерирует 8592 байт на вход

$$Q = 380 \cdot B \cdot S^2 + 8592B + 4161296 \text{ байт}$$

## Latency

Считаем 2 вещи

- количество  $F_i$  операций, GPU генерирует  $P$  операций в секунду  $\Rightarrow$  время  $\frac{F_i}{P}$

- прочитать и записать  $Q_i$  байт; память работает со скоростью  $BW$  байт в секунду, значит, на это нужно  $\frac{Q_i}{BW}$

$$t_i = \max\left(\frac{F_i}{P}; \frac{Q_i}{BW}\right) - \text{м.к. на процессор}$$

$$T = \max(t_{\text{launch}}; \sum_i \max(\frac{F_i}{P}; \frac{Q_i}{BW}))$$

Energy

Энергия - мощность на время

$$E = p_{\text{static}} \cdot e_{\text{flop}} \cdot \text{FLOPs} + c_{\text{byte}} \cdot Q; \quad \Theta_E = \begin{pmatrix} p_{\text{st}}; e_{\text{flop}} \\ e_{\text{byte}} \end{pmatrix}$$